



哈尔滨工程大学

HARBIN ENGINEERING UNIVERSITY

面向微服务系统的 故障分类工具设计与实现

毕业设计答辩

指导老师：田乔

答辩人：丁翰飞

2021108303 计算机科学与技术专业

2025.06

目录

CONTENTS

01 研究背景&意义

02 国内外研究现状

03 研究内容&成果

04 结论&展望




研究背景&意义

01 研究背景&意义



1

微服务架构



微服务架构(Microservice Architecture)是一种将单个应用程序拆分为一组小型服务的开发方法，每个服务在其独立进程中运行，并通过轻量级机制进行通信，每个服务都围绕着具体业务进行构建，并且能够被独立地部署到生产环境、类生产环境等。目前，微服务系统已经被阿里云、谷歌、微软Azure、亚马逊AWS等主要云服务提供商广泛采用。

2

微服务的特点



- 资源灵活
- 松散耦合架构
- 技术栈多样
- 轻量级部署
- 分布式系统的挑战
- 更高的运维难度
- 性能开销
- 数据管理复杂

01 研究背景&意义



哈尔滨工程大学
HARBIN ENGINEERING UNIVERSITY

3 微服务系统故障



高度动态的运行环境以及资源共享的特性使得微服务系统非常容易出现异常。微服务系统可能由于硬件导致的CPU负载过重、内存溢出、网络延迟和网络丢包等出现外部故障或由于异步交互、多实例和配置等导致内部故障。

4 研究意义



微服务系统的异常通常比单体式(**Monolithic**)开发的异常更为复杂，微服务系统的故障可能会导致非常严重的后果。因为微服务系统的运行时信息量往往非常庞大，所以面向微服务系统的自动化故障分类工具成为刚需。它可以很好的帮助开发者从复杂的监控数据中挖掘信息，从而密切地监控微服务的运行状态，及时检测并发现系统中可能存在的故障。



国内外研究现状

02 国内外研究现状



1 异常检测

❑ 传统Log-based方法

依赖日志解析工具提取日志模板并匹配事件序列，通过分析事件序列实现异常检测。

❑ 深度学习log-based方法

将日志视为自然语言序列，利用NLP方法建模日志模式。

❑ Trace-based方法

提取服务调用链（Trace）数据的调用轨迹、操作序列、延迟时间检测异常。

❑ 双模态数据融合的方法

DeepTraLog融合了调用链和日志两种监控数据。使用统一的图模型建模调用链及其相关日志的复杂关系。

2 根因定位

❑ Log-based RCA

通过比对正常与异常日志定位根因，挖掘正常日志与异常日志繁杂项集的差异，定位根因的高频项。

❑ Trace-based RCA

利用应用源代码插入Trace生成的调用链数据，分析建模服务间的依赖关系。

❑ Metric-based RCA

通过挖掘指标间关系定位故障，关联应用性能症状与资源利用情况。

❑ 多模态数据融合的方法

综合使用Log、Trace、Metrics等多模态数据，建模服务内部行为与微服务依赖关系，推断系统全貌以定位根因。



研究内容&成果

03 研究内容&成果—主要研究内容




哈尔滨工程大学
HARBIN ENGINEERING UNIVERSITY

微服务系统具有资源灵活性、松散耦合架构和轻量级部署等优势，然而高度不确定的运行环境和复杂的交互为微服务故障分类带来挑战。本研究提出一种基于多模态数据的故障分类工具，构建了包含特征提取融合、图表示学习、联合诊断的三层架构体系。




多模态特征提取&融合

构建多模态数据特征提取体系，在此基础上设计多模态数据融合器。



图表示学习

设计分层图卷积架构用于全局图表征的学习。




联合式故障分类器

通过异常检测器与根因定位器的级联设计，构建参数共享的联合式故障分类器。

03 研究内容—多模态特征提取&融合




多模态融合器采用差异化的数据处理路径，分别获得三种数据的特征表示，并采用门控线性单元对三类特征向量进行自适应融合，生成服务调用图中节点的表征向量。



03 研究内容—图表示学习



设计分层图卷积架构用于全局表征学习。通过图注意力卷积层捕获调用关系的时序演化模式，利用多头注意力权重实现异质信息融合；结合门控图卷积机制提取长程依赖特征，迭代生成拓扑感知的节点状态分布；最终采用可微分注意力池化策略，自适应强化关键节点的语义贡献，形成判别性全局图表示。




03 研究内容—联合式故障分类器



通过异常检测器与根因定位器的级联设计，构建出联合式故障分类器，将传统分离式诊断方式转化为协同优化问题。特别地，引入动态平衡因子 α 构建联合损失函数，在保证诊断精度的同时，利用特征重用机制有效降低计算开销。

$$L = \alpha L_{ad} + (1 - \alpha) L_{rca}$$



03 研究成果一 对比实验结果

在横向对比研究中，相较于基线模型（GAT、GGNN、SAGE+JK），本研究提出的GAT+GGNN融合架构展现出最优的综合性能。（为了简化过程Trace、Metrics数据的向量化中使用的简化版的自注意力层）

异常检测

模型	F1	Recall	Precision	最佳 epoch	收敛速度
GAT	0.9183	0.9859	0.8594	59	快
GGNN(3)	0.9172	0.9852	0.8579	99	慢
GGNN(5)	0.9159	0.9731	0.8651	99	慢
GAT+GGNN	0.9245	0.9785	0.8761	79	中等
SAGE+JK	0.9172	0.9852	0.8579	89	中等

根因定位

模型	HR@1	HR@3	HR@5	NDCG@1	NDCG@3	NDCG@5
GAT	0.9415	0.9751	0.9819	0.9415	0.9617	0.9644
GGNN(3)	0.8919	0.9550	0.9678	0.8919	0.9279	0.9332
GGNN(5)	0.9194	0.9530	0.9624	0.9194	0.9394	0.9433
GAT+GGNN	0.9342	0.9651	0.9718	0.9342	0.9522	0.9550
SAGE+JK	0.9382	0.9785	0.9839	0.9382	0.9623	0.9645

03 研究成果一对比实验结果



与当前多模态数据模型**Eadro**的对比分析表明，本模型在除了收敛速度以外的全部指标中优于**Eadro**。

异常检测

模型	F1	Recall	Precision	最佳 epoch
GAT+GGNN	0.9359	0.9816	0.8944	89
Eadro	0.9195	0.9806	0.8655	79

根因定位

模型	HR@1	HR@3	HR@5	NDCG@1	NDCG@3	NDCG@5
GAT+GGNN	0.9763	0.9809	0.9816	0.9763	0.9792	0.9795
Eadro	0.9398	0.9766	0.9779	0.9398	0.9624	0.9630

本模型比**Eadro**在**F1 Score**上提升**1.78%**，在**Precision**指标提升**3.34%**，**HR@1**和**NDCG@1**提升了**3.88%**。证明了本研究提出的联合式故障定位器在故障分类任务的有效性和优势。

03 研究成果—消融实验结果

使用L，T，M分别表示Log，Trace，Metrics，如果使用了多模态数据，则用“+”表示，对照组为本研究提出的模型（L+T+M），实验组在本研究模型上去除了一种或多种数据，箭头表示数据相对对照组变化。

异常检测

模型	F1	Recall	Precision
L+T+M	0.9359	0.9816	0.8944
T+M	0.9201 ↓	0.9932	0.8570 ↓
L+M	0.9246 ↓	0.9967	0.8623 ↓
L+T	0.9163 ↓	1.0000	0.8454 ↓
L	0.7897 ↓	1.0000	0.6525 ↓
T	0.9150 ↓	0.9986	0.8443 ↓

多模态数据组拥有最高的F1和Precision分数，说明多模态模型综合分类性能最优，误报控制能力最强。表明多模态数据通过融合日志（L）、追踪（T）、指标（M）的互补信息，能更全面地捕捉故障特征，减少误判。

03 研究成果—消融实验结果



在根因定位中L+T+M的HR@1与NDCG@1高于T+M以外的所有组，证明其在快速、准确的定位故障所在微服务方面具有优势。

根因定位

模型	HR@1	HR@3	HR@5	NDCG@1	NDCG@3	NDCG@5
L+T+M	0.9763	0.9809	0.9816	0.9763	0.9792	0.9795
T+M	0.9837	0.9925	0.9925	0.9837	0.9892	0.9892
L+M	0.9727 ↓	0.9834	0.9893	0.9727 ↓	0.9792	0.9816
L+T	0.3527 ↓	1.0000	1.0000	0.3527 ↓	0.7184 ↓	0.7184 ↓
L	0.0296 ↓	0.1017 ↓	0.1711 ↓	0.0296 ↓	0.0701 ↓	0.0986 ↓
T	0.3477 ↓	0.9986	0.9986	0.3477 ↓	0.7159 ↓	0.7159 ↓

多模态数据在对故障分类有着明显正向的影响，使用多模态数据进行故障分类可以获得最佳的综合性能。



结论&展望

04 结论&展望



哈尔滨工程大学
HARBIN ENGINEERING UNIVERSITY

结论

- 设计了多模态特征提取体系和多模态数据融合器。为使用多模态数据进行故障分类研究提供思路和方法。
- 设计了用于学习全局表征的分层图卷积架构，并通过对比实验验证了其具有较强的综合性能。
- 构建了参数共享的联合分类架构，在保证分类精度的同时有效降低计算开销。
- 通过多组数据消融实验深入解析模型组件，实验结果表明，联合建模策略通过特征交互增强有效解决了传统方法中数据利用不充分的问题。

展望

- 特征向量化方法的部分仍有改进空间，如对**Log**数据的处理可以引入先进的**NLP**方法。
- 图表示学习模块可以尝试更深层的图卷积网络架构，或更多样的图卷积网络。
- 可以设计多组对比实验探究联合式故障分类器在计算开销方面具体的降低程度。目前在理论上可以降低一半的计算开销。
- 可以拓展故障的种类，探究模型是否依然能很好地完成故障分类任务。



哈尔滨工程大学
HARBIN ENGINEERING UNIVERSITY

谢谢!

丁翰飞
哈尔滨工程大学
计算机科学与技术专业